Hierarchiniai tiesiniai modeliai (HLM)

Hierarchical Linear Modeling

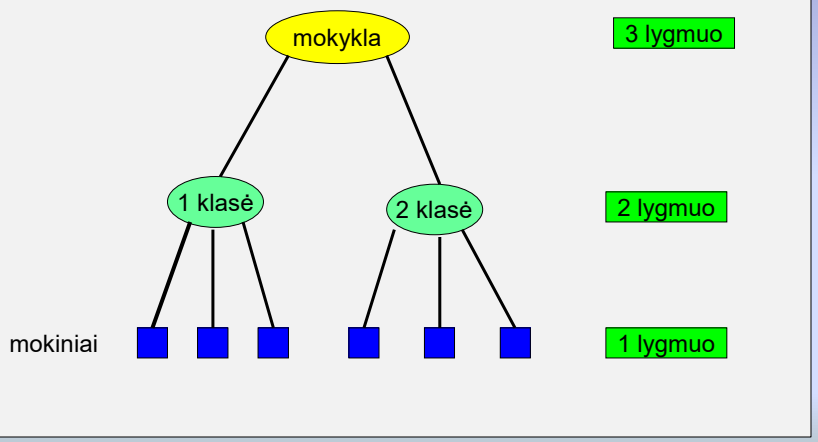
(Mixed Models)

Kas tas HLM?

- **Matematiškai HLM yra tiesinės regresijos apibendrinimas atvejui, kai koeficientai prie regresorių savo ruožtu yra atsitiktiniai dydžiai, kuriems irgi galima sudaryti regresinius modelius.**
- **Praktikoje HLM reiškia, kad modeliuodami atsižvelgiame į hierarchinę duomenų struktūrą.**

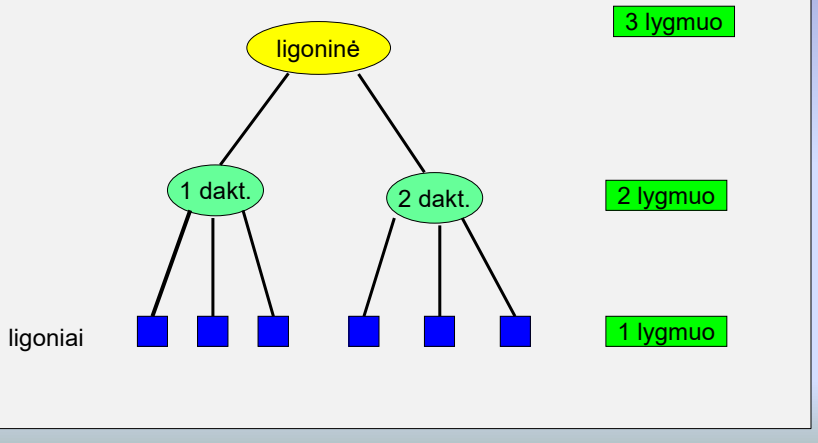
2

Hierarchinė sruktūra



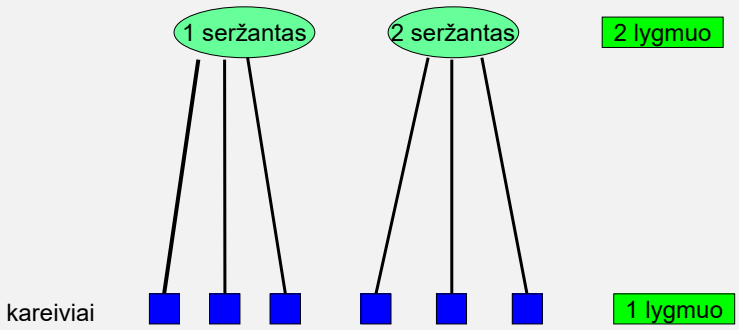
3

Hierarchinė sruktūra



4

Hierarchinė sruktūra



5

Hierarchinė sruktūra

- sirgimo covid-19 eigos priklausomybė nuo ligonio sveikatos būklės, amžiaus ir antsvorio (I lygmuo) ir nuo gydytojo (II lygmuo).
- kriminologas tiria jaunimo polinkio į nusikalstamumą priklausomybę nuo respondento šeimos socialinių ir ekonominių parametrų (I lygmuo), gyvenamojo rajono kriminogeniškumo (II lygmuo) ir nuo miesto didumo (III lygmuo).

6

Hierarchinė sruktūra

- Pirmasis lygmuo yra žemiausias.
- Elementai apibrėžiami kiekviename lygmenyje.





7

Bandymai išsisukti

- Deagregavimas: ignoruojame, kad informacija kartojasi (mokytojas moko kelis mokinius) ir apsimetame, kad tai mokinio charakteristika.
- Pasekmė: kintamųjų standartinės paklaidos tampa mažesnėmis, nei turėtų būti -> pasikliautinieji intervalai tampa nepagrįstai trumpais ->nulinė hipotezė atmetama rečiau, nei derėtų (ir norėtųsi).

8

Bandymai išsisukti

- Agregavimas: suvidurkiname I lygmens charakteristikas (mokinių) ir pereiname prie II lygmens modeliavimo.
- Pasekmė – nepanaudojame daug informacijos, o ir modeliuojame ne visada tai, ką norime.
- Kartais modeliai net išsikraipo.

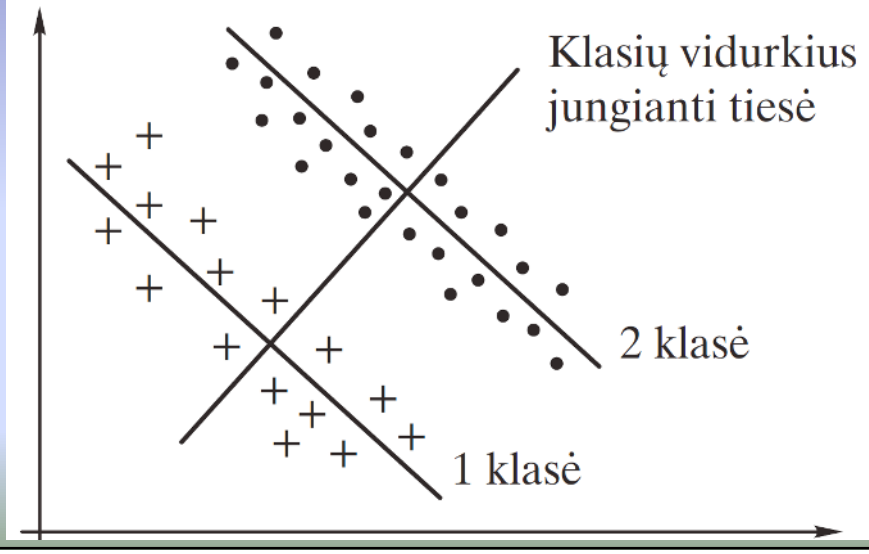
9

Nesėkmingo agregavimo pavyzdys

- Tarkime, kad tirta dviejų klasių mokinių matematinio testo klaidų skaičiaus priklausomybė nuo testo trukmės. Jeigu kiekvienos klasės duomenys tiriami atskirai, tai gaunama natūrali priklausomybė – kuo ilgiau daromas testas, tuo mažiau klaidų.
- Kita vertus, jeigu imami klasių vidurkiai, tai juos jungianti tiesė rodo priešingą priklausomybę.

10

Nesėkmingo agregavimo pavyzdys



Bendra HLM idėja

- Pirmas lygmuo (primena regresiją)

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + e.$$

- Antras lygmuo (primena daug regresijų)

$$\begin{aligned}
\beta_0 &= \gamma_{00} + \gamma_{01} W_1 + u_0, \\
\beta_1 &= \gamma_{10} + \gamma_{11} W_1 + u_1, \\
\beta_2 &= \gamma_{20} + \gamma_{21} W_1 + \gamma_{22} W_2 + u_2, \\
\beta_3 &= \gamma_{30} + \gamma_{32} W_2 + u_3.
\end{aligned}$$

12

Tipiška HLM sudarymo eiga

- Iš pradžių visada sudaromas besąlyginis (nulinis) modelis.
- Sudaromas sudėtingesnis modelis.
- Modeliai lyginami, aiškinamasi, kuris geresnis.
- tęsiame tol, kol gauname įmanomai gerą modelį
- arba išvadą, kad tokio modelio nėra.

13

Pastabos

- Stebinių turi būti pakankamai daug kiekviename lygmenyje. Negalima sudarinėti HLM, kai mokyklos tik dvi.
- Dauguma kintamųjų – normalūs.
- Modeliuosime mokinio matematikos pasiekimus (MAT), atsižvelgdami į mokinio (I lygmuo) ir mokyklos (II lygmuo) charakteristikas.
- .

14

1 žingsnis: besąlyginis HLM

- Besąlyginis (nulinis) modelis svarbus tuo, kad su juo lyginami kiti hierarchiniai modeliai.
- Besąlyginio modelio analizė padeda atsakyti į klausimą, ar apskritai galima kalbėti apie hierarchinių modelių tinkamumą.

15

Besąlyginis HLM modelis

Vadovausimės tokia logika:

- mokinio rezultatų ir visos mokyklos vidurkio skirtumas atspindi tai, kas būdinga tik tam mokiniui – jo gabumus, namų aplinką, repetitoriaus patirtį ir pan. :

Mokinio rezultatas = mokyklos vidurkis + individualūs skirtumai nuo vidurkio.

- Analogiškai aprašome mokyklos lygmenį:

Mokyklos rezultatas = visų mokyklų vidurkis+ šios mokyklos įtaka.

16

Besąlyginio HLM modelio idėja

- Mokinio lygmuo:

$$\mathrm{MAT} = \beta_0 + \mathrm{e}$$

- Mokyklos lygmuo:

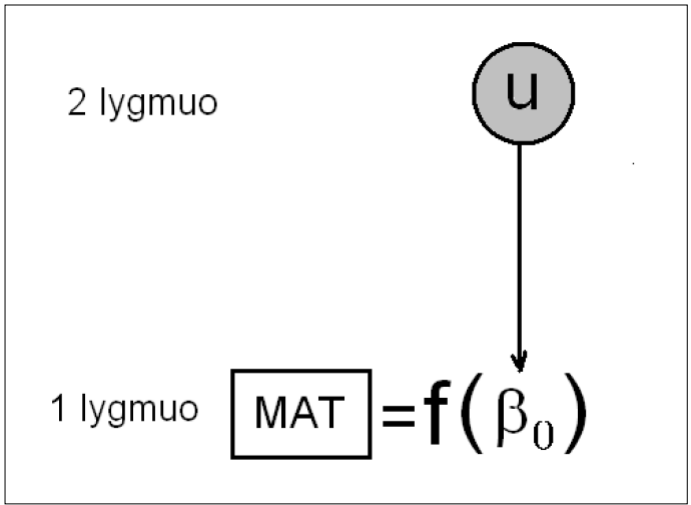
$$\beta_0 = \gamma_{00} + \mathrm{u}_0$$

- **Jungtinis modelis:**

$$\mathrm{MAT} = \gamma_{00} + \mathrm{u}_0 + \mathrm{e}$$

17

MODELIO IDĖJA



18

Jungtinis besąlyginis modelis

$$\mathrm{MAT} = \gamma_{00} + \mathrm{u}_0 + \mathrm{e}$$

- Parametras γ_{00} nusako visų mokyklų matematikos testo rezultatų vidurkį.
- Mokyklų skirtumus rodo kintamojo u_0 **dispersija** τ_{00}.
- Mokinių individualius skirtumus rodo kintamojo e **dispersija** σ^2 .
- Kuo dispersijos didesnės, tuo didesni ir atitinkami skirtumai.

19

Terminai

- γ_{00} – fiksuoto poveikio parametras,

τ_{00} ir σ^2 – atsitiktinio poveikio parametrai.

20

Besąlyginio modelio tyrimo rezultatai

Parametro γ_{00} įvertis $\hat{\gamma}_{00} = 499{,}47$

Be to, patikrinama hipotezė

$$\begin{cases} H_0: \gamma_{00} = 0 \\ H_1: \gamma_{00} \neq 0 \end{cases}$$

Gauta, kad $\gamma_{00} \neq 0$ statistiškai reikšmingai.

21

Besąlyginio modelio tyrimo rezultatai

- Primename, kad γ_{00} – tai bendras visų mokyklų matematikos testo MAT vidurkis.
- Statistinės hipotezės išvada, kad jis nelygus nuliui, nėra itin vertinga (niekas ir nesitikėjo, kad visi bus beraščiai).
- Įvertis $\hat{\gamma}_{00} = 499{,}47$ – daug svarbesnis.

22

Besąlyginio modelio tyrimo rezultatai

Tikrinamos dvi hipotezės apie I ir II lygmenų paklaidų dispersijas:

$$\begin{cases} H_0: \tau_{00} = 0 \\ H_1: \tau_{00} > 0 \end{cases} \qquad \begin{cases} H_0: \sigma^2 = 0 \\ H_1: \sigma^2 > 0 \end{cases}$$

23

Besąlyginio modelio tyrimo rezultatai

- Abi nulinės hipotezės atmetamos, daroma išvada, kad $\tau_{00} > 0$ ir $\sigma^2 > 0$.
- Gavome patvirtinimą, kad modelis ne iki galo paaiškina rezultatų skirtumus.

24

Besąlyginio modelio tyrimo rezultatai

Gauti dispersijų įverčiai yra dideli:

$\hat{\tau}_{00} = 2356{,}11$ ir $\hat{\sigma}^2 = 5117{,}19$

Modelis duomenims tinka blogai (dar daug nepaaiškintų rezultatų skirtumų ir skirtumų tarp mokyklų).

25

Tarpklasinė koreliacija

- Antrojo lygmens liekanos dispersija τ_{00}
- Pirmojo lygmens liekanos dispersija σ^2
- Skaičiuojame, naudodami jų įverčius (todėl kepurėlės).

$$\text{ICC} = \frac{\hat{\tau}_{00}}{\hat{\tau}_{00} + \hat{\sigma}^2}$$

26

Tarpklasinė koreliacija

- **ICC** (*Intraclass correlation coefficient)*, parodo, kaip stipriai skiriasi grupių (mokyklų) rezultatai, palyginti su rezultatais grupėse.

$$\text{ICC} = \frac{\hat{\tau}_{00}}{\hat{\tau}_{00} + \hat{\sigma}^2}$$

- Kuo **ICC** didesnis, tuo labiau tikėtina, kad reikia atsižvelgti į hierarchinę duomenų struktūrą.

27

Pavyzdys

- Tegul

$\hat{\tau}_{00} = 2356{,}11$ $\hat{\sigma}^2 = 5117{,}19$

Tada $\text{ICC} = \frac{2356{,}11}{2356{,}11 + 5117{,}19} = 0{,}315\ldots$

Interpretuojama taip: apie 31,5 procento mokinio rezultatų priklauso nuo mokyklos.

28

Išvada

- Ir ICC, ir atsitiktinių parametrų įverčiai rodo, kad reikia sudaryti sudėtingesnį modelį.
- Įtraukdami naujus I ir II lygmenų kintamuosius, siekiame sumažinti įverčių

$\hat{\tau}_{00} = 2356{,}11$ $\hat{\sigma}^2 = 5117{,}19$

didumus (jie parodo tuos mokinių ir mokyklų skirtumus, kurių nepaaiškina modelis).

29

Įvairūs modeliai

- Kintamieji

$CSES_{ij}$ – mokyklos vidurkiu centruotas i-ojo mokinio socekonominis statusas j-ojoje mokykloje;
$MSES_j$ – j-osios mokyklos socek statuso vidurkis
VK_j – mokyklos tipas (0 – Vilniaus, 1 – kaimo)
MAT_{ij} – matematikos testo rezultatai.

30

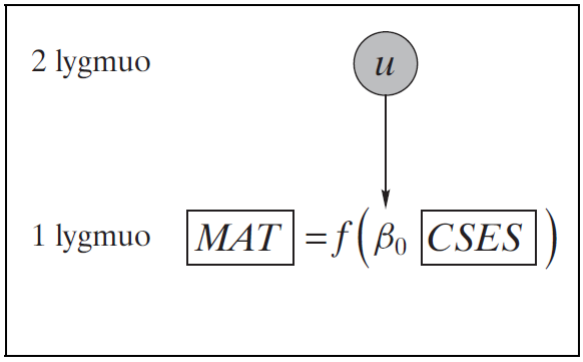
1. Pastovaus posvyrio modelis

- Tarkime, kad kiekvieno mokinio matematikos testo rezultatai *MAT* priklauso tik nuo *CSES* ir priklausomybė visose mokyklose tokia pat, tačiau gali skirtis papildomas mokyklos indėlis.
- *CSES* yra normalus kintamasis.
- Visos liekamosios paklaidos normalios su lygiomis dispersijomis atitinkamuose lygmenyse.

31

1. Pastovaus posvyrio modelis

- Grafiškai



32

1. Pastovaus posvyrio modelis

- Pirmas lygmuo

$$MAT = \beta_0 + \beta_1 CSES + e$$

- Antras lygmuo

$$\beta_0 = \gamma_{00} + u_0$$

$$\beta_1 = \gamma_{10}$$

- Priklausomybė nuo *CSES* visose mokyklose vienoda (nes β_1 visur tas pats)

33

1. Pastovaus posvyrio modelis

- Jungtinė lygtis:

$$MAT = [\gamma_{00} + \gamma_{10} CSES] + [u_0 + e]$$

- Įvertinę modelį, gausime γ_{00}, γ_{10} ir τ_{00} (u_0 dispersijos) bei σ^2 (e dispersijos) įverčius.
- Jungtinę lygtį galima naudoti prognozėms.

34

2. Modelis su antrojo lygmens intervaliniu kintamuoju

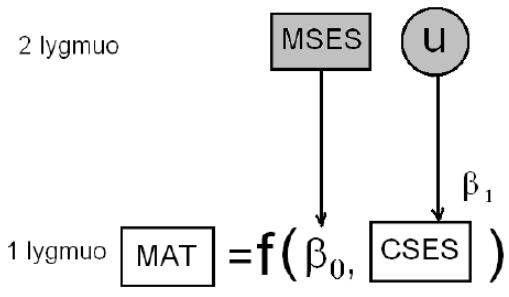
Manome, kad:

- mokinio matematikos testo rezultatas priklauso nuo jo socialinio ir ekonominio statuso (CSES);
- mokykos įtaka visiems mokiniams vienoda;
- mokyklos įtakos stiprumą lemia jos mokinių socialinio ir ekonominio statuso vidurkis (MSES).

35

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Grafiškai modelis atrodo taip:



36

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Reikalavimai kintamiesiems:

- Priklausomas kintamasis (**MAT**) būtinai turi būti intervalinis.
- Kiti kintamieji yra intervaliniai arba kategoriniai (pseudokintamieji).
- Šiame pavyzdyje visi kiti kintamieji (**CSES** ir **MSES**) yra intervaliniai.
- Paklaidos (liekanos) – normaliai pasiskirsčiusios ir nepriklausomos.

37

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Pasižiūrime, kurio lygmens kintamųjų turime:

- pirmojo (mokinio) lygmens kintamasis yra **CSES** .
- antrojo (mokyklos) lygmens kintamasis yra **MSES**.

38

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Mokinio lygmens lygtis gana akivaizdi:

$$\mathrm{MAT} = \beta_0 + \beta_1 \mathrm{CSES} + \mathrm{e}.$$

Čia e žymi atsitiktinę paklaidą, kuri yra normaliai pasiskirsčiusi su nuliniu vidurkiu ir nežinoma dispersija σ^2 . Ši dispersija atspindi mokinių skirtumus, atsiradusius ne dėl mokyklų įtakos.

39

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Antrojo lygmens kintamieji į modelį įtraukiami, tariant, kad atitinkami β koeficientai yra atsitiktiniai.

Laikomasi tokio principo:

- Kintamieji, kurie veikia visus mokinius vienodai, įtraukiami į lygtį, aprašančią laisvą narį β_0 .
- Kintamieji, kurie turi sąveiką su **CSES**, įtraukiami į lygtį, aprašančią koeficientą β_1 .

40

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Taigi antrojo lygmens lygtys yra tokios:

$$\beta_0 = \gamma_{00} + \gamma_{01}\mathrm{MSES} + \mathrm{u}_0,$$

$$\beta_1 = \gamma_{10} + \mathrm{u}_1.$$

Čia γ_{ij} — nežinomos konstantos.

Paklaidos $\mathrm{u}_0, \mathrm{u}_1$ turi dispersijas τ_{00}, τ_{11} ir gali koreliuoti (kovariacija τ_{01}).

41

2. Modelis su antrojo lygmens intervaliniu kintamuoju

- Primename, kad dispersijos

$$\tau_{00}, \tau_{11}$$

atspindi rezultatų skirtumus, atsirandančius dėl mokyklų įtakos.

- Tačiau tik tuos skirtumus, kurių nepaaiškina pasirinktasis modelis.
- Kuo šios dispersijos mažesnės, tuo modelis geriau tinka duomenims.

42

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Galima sudaryti jungtinę lygtį

$$\mathrm{MAT} = [\gamma_{00} + \gamma_{01}\mathrm{MSES} + \gamma_{10}\mathrm{CSES}] + [\mathrm{e} + \mathrm{u}_0 + \mathrm{u}_1\mathrm{CSES}].$$

Matome, kad modelyje išsiskiria du komponentai:

- fiksuoto poveikio;
- atsitiktinio poveikio.

43

2. Modelis su antrojo lygmens intervaliniu kintamuoju

- Fiksuoto (pastovaus) poveikio parametrai yra

$$\gamma_{00}, \gamma_{01}, \gamma_{10}$$

- Atsitiktinio poveikio parametrai (liekanų $\mathrm{e}, \mathrm{u}_0, \mathrm{u}_1$ dispersijos ir kovariacijos) yra

$$\tau_{00}, \tau_{11}, \tau_{01}, \sigma^2$$

44

2. Modelis su antrojo lygmens intervaliniu kintamuoju

- Kintamieji prie γ vadinami fiksuoto poveikio kintamaisiais, o kintamieji prie u – atsitiktinio poveikio kintamaisiais.
- Fiksuoto poveikio kintamieji: **CSES** ir **MSES**.
- Atsitiktinio – kintamasis **CSES** .

$$\mathrm{MAT} = [\gamma_{00} + \gamma_{01}\mathrm{MSES} + \gamma_{10}\mathrm{CSES}] + [\mathrm{e} + \mathrm{u}_0 + \mathrm{u}_1\mathrm{CSES}]$$

45

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Visi fiksuoto poveikio parametrai buvo statistiškai reikšmingi ir

$$\hat{\gamma}_{01} = 16{,}56$$

$$\hat{\gamma}_{00} = 175{,}94$$

$$\hat{\gamma}_{10} = 8{,}04$$

46

2. Modelis su antrojo lygmens intervaliniu kintamuoju

- Atsitiktinio poveikio parametrų įverčiai

$\hat{\tau}_{00} = 559{,}48$

$\hat{\tau}_{11} = 9{,}19$

$\hat{\tau}_{01} = 0{,}371$

$\hat{\sigma}^2 = 4290{,}92$

47

2. Modelis su antrojo lygmens intervaliniu kintamuoju

- Gauta, kad β_0 ir β_1 nekoreliuoja (p= 0,99) .
- Antro lygmens lygtis β_1 pakankamai gerai aprašo mokyklos įtaką, nes
- $\hat{\tau}_{01} = 0{,}371$ (maža) and p=0,992.
- O β_0 antro lygmens lygtis dar ne itin gera (. $\hat{\tau}_{00} = 559{,}48$ didelė)

48

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Įsitikiname, kad respondentų skirtumus atspindinti dispersija nėra itin maža:

$$\hat{\sigma}^2 = 4290{,}92$$

Vis dėlto, lyginant su besąlyginio modelio analogiška dispersija ($5117{,}19$), aišku, kad dispersija itin sumažėjo.

Galima ištirti, kuri dalis dispersijos dingo.

49

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Formulė:

$$\frac{\hat{\sigma}^2_{sena} - \hat{\sigma}^2_{nauja}}{\hat{\sigma}^2_{sena}}$$

Gauname:

$$\frac{5117{,}19 - 4290{,}92}{5117{,}19} = 0{,}161\ldots$$

Interpretuojame taip: lyginant su besąlyginiu modeliu, 16% sumažėjo modeliu nepaaiškintų mokinių rezultatų skirtumų. Gana nemenkas išlošis.

50

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Akaikės ir kitų indeksų sumažėjimas bent per 10 vienetų jau laikomas svarbiu.

Information Criteria[a]

-2 Restricted Log Likelihood	6109,830
Akaike's Information Criterion (AIC)	6117,830
Hurvich and Tsai's Criterion (AICC)	6117,904
Bozdogan's Criterion (CAIC)	6138,996
Schwarz's Bayesian Criterion (BIC)	6134,996

The information criteria are displayed in smaller-is-better forms.

a. Dependent Variable: MAT.

Nujasis modelis

Information Criteria[a]

-2 Restricted Log Likelihood	6415,181
Akaike's Information Criterion (AIC)	6419,181
Hurvich and Tsai's Criterion (AICC)	6419,202
Bozdogan's Criterion (CAIC)	6429,829
Schwarz's Bayesian Criterion (BIC)	6427,829

The information criteria are displayed in smaller-is-better forms.

a. D

Besąlyginis

51

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Išvados:

- Nagrinėjamas modelis daug geriau tinka duomenims nei besąlyginis modelis.
- Testo rezultatai matuojami šimtais balų, todėl rezultatų paklaidos standartinis nuokrypis nėra labai didelis $\hat{\sigma} = 65{,}49\ldots$
- Modelį galima laikyti pakankamai geru.
- Žinoma, tai nereiškia, kad nėra geriau duomenims tinkančių modelių.

52

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Norėdami prognozuoti, tiesiog įstatome fiksuotųjų parametrų įverčius į jungtinę lygtį

$$\widehat{\text{MAT}} = \hat{\gamma}_{00} + \hat{\gamma}_{01}\text{MSES} + \hat{\gamma}_{10}\text{CSES}$$

Mūsų nagrinėjamu atveju

$$\widehat{\text{MAT}} = 175{,}94 + 16{,}56\text{MSES} + 8{,}04\text{CSES}$$

53

2. Modelis su antrojo lygmens intervaliniu kintamuoju

Įstatę konkrečias kintmųjų CSES ir MSES reikšmes, gautume testo rezultato prognozę konkrečiam mokiniui.

Be to, ši regresinė lygtis leidžia įvertinti mokyklos įtaką. Iš tikro kiekvienas papildomas MSES balas padidina testo rezultatą 16,56 taško:

$$\widehat{\text{MAT}} = 175{,}94 + 16{,}56\text{MSES} + 8{,}04\text{CSES}$$

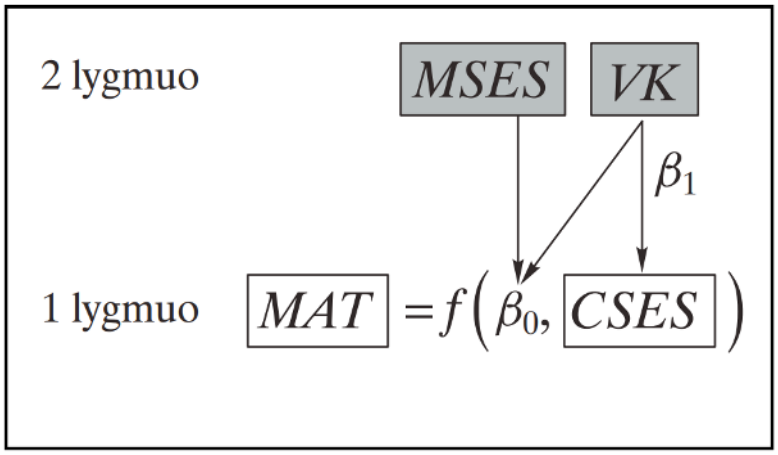
54

3. Modelis su kategoriniu kintamuoju

- Ištirsime modelį su antrojo lygmens kategoriniu kintamuoju **VK** (0-Vilnius, 1-kaimas), nurodančiu mokyklos priklausomybę Vilniaus miestui.
- Tirsime ankstesnį modelį, papildytą šiuo antrojo lygmens kintamuoju.
- Suformuluosime sąlygas tiksliau.

55

3 modelis. Grafiškai



56

3 modelis. Lygtys (idėja)

- Mokinio matematikos testo rezultatas priklauso nuo jo socialinio ir ekonominio statuso:

$$\mathrm{MAT} = \beta_0 + \beta_1 \mathrm{CSES} + \mathrm{e}$$

- Mokyklos įtaka priklauso nuo mokyklos socialinio ir ekonominio statuso vidurkio bei mokyklos vietos:

$$\beta_0 = \gamma_{00} + \gamma_{01} \mathrm{MSES} + \gamma_{12} \mathrm{VK} + \mathrm{u}_0$$

57

3 modelis. Charakteristikos

Vilniaus mokyklose socialinio ir ekonominio statuso reikšmė kitokia nei kitose mokyklose:

$$\beta_1 = \gamma_{10} + \gamma_{11} \mathrm{VK} + \mathrm{u}_1;$$

čia e turi dispersiją σ^2;

paklaidos $\mathrm{u}_0, \mathrm{u}_1$ turi dispersijas $\tau_{00}, \tau 11$ ir gali koreliuoti (kovariacija τ_{01}).

58

3 modelis

- Jungtinė lygtis:

$$\begin{aligned}\mathrm{MAT} = \gamma_{00} + \gamma_{01}\mathrm{MSES} + \gamma_{10}\mathrm{CSES} \\ + \gamma_{02}\mathrm{VK} + \gamma_{12}\mathrm{VK} \times \mathrm{CSES} \\ +[\mathrm{u}_1\mathrm{CSES} + \mathrm{u}_0 + \mathrm{e}].\end{aligned}$$

- Fiksuotieji kintamieji: CSES, MSES, VK, VKxCSES .
- Atsitiktiniai kintamieji: CSES.
- CSES priklauso abiem grupėm.

59

3 modelis. Tikslai.

- Payginsime informacinius indeksus.
- Patikrinsime parametrų (fiksuotų ir atsitiktinių) statistinį reikšmingumą.
- Sudarysime prognozėms tinkamą modelį.
- (Pažiūrėsime dispersijos pokytį.)

60

3 modelis. Akaikės indeksas.

- 10 vienetų pokytis jau yra svarbus.

Information Criteria[a]

-2 Restricted Log Likelihood	6091,135
Akaike's Information Criterion (AIC)	6099,135
Hurvich and Tsai's Criterion (AICC)	6099,210
Bozdogan's Criterion (CAIC)	6120,286
Schwarz's Bayesian Criterion (BIC)	6116,286

Naujas modelis

Information Criteria[a]

-2 Restricted Log Likelihood	6109,830
Akaike's Information Criterion (AIC)	6117,830
Hurvich and Tsai's Criterion (AICC)	6117,904
Bozdogan's Criterion (CAIC)	6138,996
Schwarz's Bayesian Criterion (BIC)	6134,996

The information criteria are displ… forms.

a. Dependent Variable: MAT.

Senesnis modelis

61

3 modelis. Parametrai.

Ne visi fiksuotų efektų parametrai statistiškai reikšmingi (laisvam nariui nežiūrime).

```
## Fixed effects: MAT ~ 1 + CSES + MSES + VK + VK * CSES
##                    Value Std.Error  DF   t-value p-value
## (Intercept)     47.23318  60.83742 514  0.776384  0.4379
## CSES             7.27030   1.55839 514  4.665277  0.0000
## MSES            23.93195   3.31679  24  7.215397  0.0000
## VKVilnius      -47.92946  17.50487  24 -2.738064  0.0115
## CSES:VKVilnius   2.07155   2.59352 514  0.798740  0.4248
```

62

3 modelis. Parametrai.

Iššifravimas:

$$\begin{aligned}\text{MAT} &= \gamma_{00} + \gamma_{01}\text{MSES} + \gamma_{10}\text{CSES} \\ &\quad + \gamma_{02}\text{VK} + \gamma_{12}\text{VK} \\ &\times \text{CSES+atsit.dalis}\end{aligned}$$

$$\begin{aligned}\hat{\gamma}_{00} &= 47.233 \\ \hat{\gamma}_{01} &= 23.93 \\ \hat{\gamma}_{10} &= 7.27 \\ \hat{\gamma}_{02} &= -47.93 \\ \hat{\gamma}_{12} &= 2.07\end{aligned}$$

```
## (Intercept)      47.23318
## CSES              7.27030
## MSES             23.93195
## VKVilnius       -47.92946
## CSES:VKVilnius    2.07155
```

63

3 modelis. Modelio įvertis.

Kaimui:

$$\widehat{\text{MAT}} = -0.6 + 23.9\text{MSES} + 9.34\text{CSES}$$

Vilniui:

$$\widehat{\text{MAT}} = 47.23 + 23.9\text{MSES} + 7.27\text{CSES}$$

64

3 modelis. Dispersijos

Pirmas lygmuo

$\hat{\sigma}^2 = 65{,}528515^2 = 4293{,}9 \ldots$

Antras lygmuo:

$\hat{\tau}_{00} = 19{,}524824^2 = 381{,}2 \ldots$
$\hat{\tau}_{11} = 3{,}205892^2 = 10{,}27 \ldots$

65

3 modelis. Koreliacija

Antras lygmuo:

$Corr(u_0, u_1) = 0{,}146.$

Todėl

$\hat{\tau}_{11} = Corr(u_0, u_1)\sqrt{\hat{\tau}_{00} \cdot \hat{\tau}_{11}}$
$= 0{,}146 \cdot 19{,}52 \cdot 3{,}20 = 9{,}119 \ldots.$

66

3 modelis. Koreliacija

Ar reikia skaičiuoti dispersijas ir kovariacijas vietoje standartinių nuokrypių ir koreliacijos?

Žinoma, kad **nereikia**. Standartiniai nuokrypiai turi tiek pat informacijos apie skirtumus tarp duomenų, kiek ir dispersijos.

Koreliacija leidžia „iš akies“ įvertinti priklausomybės stiprumą (0,146 – labai silpna koreliacija).

67

3 modelis. Preliminarios išvados.

- Modelis ne itin geras.
- Galbūt reikia išmesti VK*CSES.
- Galbūt reikia išmesti γ_{00}.
- Dar reikėtų kintamųjų normalumą (ypač MAT) patikrinti.

68

PASTABOS

- Modelio tobulinimas vyksta, mažinant atsitiktinių poveikių dispersijas.
- Įtraukus naujus kintamuosius, tikimės, kad jos sumažės.
- Tačiau, kaip taisyklė, pridėjus antro lygmens kintamąjį, antro lygmens dispersijos mažėja, bet pirmo lygmens padidėja.
- Laimei, nedaug. Todėl to bijoti nereikia.
- .

69

PASTABOS

- Paprastai parametrai vertinami apribotojo didžiausio tikėtinumo (REML) metodu.
- Dar naudojamas didžiausio tikėtinumo (ML) metodas.
- REML efektyvesnis už ML, kai kintamieji stipriai koreliuoja.
- ML dažniausiai duoda mažesnius kovariacijų-dispersijų įverčius (ir daro tyrėją laimingesniu).

70

PASTABOS

- Tarkime, vienas modelis yra kito modelio dalinis atvejis. Tada R yra galimybė palyginti tuos du modelius. Jeigu jie stat. reikšmingai nesiskiria, imamas paprastesnis.
- Tačiau tai galima daryti tik, kai parametrų įverčiai randami naudojant ML (didžiausio tikėtinumo) metodą.

71

PASTABOS

- Matome, kad 3 modelis su VK ir tarpusavio sąveika yra statistiškai reikšmingai geresnis, nei 2 modelis.
- Bet AIC pokytis kuklus (mažiau 10).

```
model.1ml<-update(model.1, method = "ML")
model.2ml<-update(model.2, method = "ML")
anova(model.1ml, model.2ml)
```

```
##           Model df      AIC      BIC    logLik   Test  L.Ratio p-value
## model.1ml     1  7 6134.547 6164.627 -3060.273
## model.2ml     2  9 6130.467 6169.141 -3056.233 1 vs 2 8.080262  0.0176
```

72

PRIELAIDŲ TIKRINIMAS

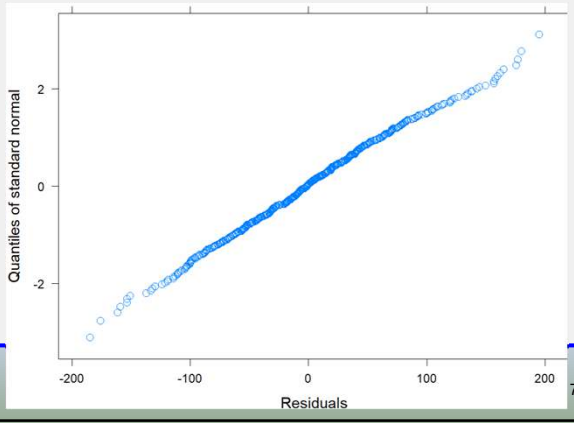
- Abiejų lygių liekamosios paklaidos turi būti normalios.
- Tą galima patikrinti bent jau grafiškai.
- Tarkime, kad sudarėme HLM duomenims

> model.1<-lme(MAT~1+MSES+CSES, data=data, random= ~1+CSES|IDMOK)

73

PRIELAIDŲ TIKRINIMAS

- Pažiūrime liekamųjų (e) paklaidų q-q grafiką:
- > qqnorm(model.1,~resid(.))
- Visai panašu į normalumą.

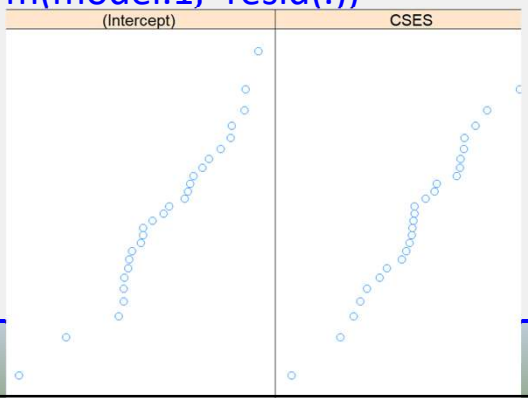


74

qqnorm(model.1,~ranef(.))

PRIELAIDŲ TIKRINIMAS

- Galima pažiūrėti ir atsitiktinių kintamųjų, bei posvyrių q-q grafikus:
- > qqnorm(model.1,~resid(.))



75

Svarbi problema

Jei **I** lygmenyje įtrauktas labai stipriai su rezultatu koreliuojantis kintamasis, tai paaiškės, kad joks HLM modelis netinka.

Pavyzdžiui, įtraukus fizikos testo rezultatą FIZ

$$\mathrm{MAT} = \beta_0 + \beta_1 \mathrm{FIZ} + \mathrm{e},$$

paaiškės, kad geriau mokantys fiziką, geriau ir matematiką išmano. Ir kas iš to? Norint pagerinti matematikos žinias, reikia sustiprinti fizikos mokymą? Kažin, kažin.

76

Svarbi problema

Modelį reikia sudaryti sąmoningai mąstant apie tyrimo tikslus, o ne pagal stipriausias koreliacijas.

Norime sužinoti, **kas daro įtaką** matematikos žinioms.

Pavyzdžiui:

- koks yra mokyklos vaidmuo (II lygmuo);
- koks yra socialinio ir ekonominio statuso vaidmuo (I lygmuo).

77

METODINIAI PATARIMAI

Pradedama nuo besąlyginio modelio.

Nustatoma, kurie kintamieji yra pastovaus poveikio, o kurie – kintamojo . Tam atliekami tokie veiksmai:

1) Įvardijami pirmojo ir antrojo lygmens kintamieji.
2) Apibrėžiamos spėjamos priklausomybės.
3) Lygtimis užrašoma, kas nuo ko priklauso. Reikia nepamiršti antrojo lygmens lygtyse pridėti atsitiktinę paklaidą u. Pirmojo lygmens lygtyje pridedama **e**.
4) Antrojo lygmens lygtis įstatoma į pirmojo lygmens lygtį.
5) Jungtinėje lygtyje surenkami nariai prie **u** ir **e**.
6) Kintamieji be **u** yra pastovaus poveikio; kintamieji su u – atsitiktinio poveikio. Beje, tas pats kintamasis gali būti ir pastovaus ir atsitiktinio poveikio.

78

METODINIAI PATARIMAI

- Modeliuoti liaujamasi, kai išsibaigia kintamieji ir idėjos.
- Pateikiamas geriausias modelis.

79

Tikslios matematinės formuluotės

Besąlyginis HLM modelis tiksliau

- Tarkime turime **J** mokyklų, t.y. *j* = 1, 2, . . ., **J**, o *j*-oje mokykloje yra $\mathbf{n}_j$ mokinių. Mokinio lygmuo:

$$MAT_{ij} = \beta_{0j} + e_{ij}, i = 1,\ldots,n_j,\ j = 1,\ldots,J.$$

- Mokyklos lygmuo:

$$\beta_{0j} = \gamma_{00} + u_{0j}, j = 1,2,\ldots,J.$$

81

Besąlyginis HLM modelis tiksliau

- Prielaidos:

$e_{ij} \sim N(0, \sigma^2)$ nepriklausomi, $i = 1,\ldots,n_j, j = 1,\ldots,J.$

$u_{0j} \sim N(0, \tau_{00})$ nepriklausomi, $j = 1,\ldots,J.$

e_{ij} ir u_{0j} nekoreliuoja

82

Interpretacija

β_{0j} yra *j*-osios mokyklos rezultatų vidurkis;

e_{ij} i-jo mokinio rezultatų skirtumai nuo *j* mokyklos vidurkio;

σ^2 mokinių gabumų dispersija;

γ_{00} bendrasis visų mokyklų mokinių rezultatų vidurkis

τ_{00} mokyklų skirtumų dispersija.

83

Besąlyginis modelis

- Jungtinis modelis

$$Y_{ij} = \gamma_{00} + u_{0j} + e_{ij}$$

- Hipotezės

$$\begin{cases} H_0: \gamma_{00} = 0 \\ H_1: \gamma_{00} \neq 0 \end{cases} \quad \begin{cases} H_0: \tau_{00} = 0 \\ H_1: \tau_{00} > 0 \end{cases} \quad \begin{cases} H_0: \sigma^2 = 0 \\ H_1: \sigma^2 > 0 \end{cases}$$

84

Besąlyginis modelis

$$Y_{ij} = \gamma_{00} + u_{0j} + e_{ij}$$

- τ_{00} atspindi antro lygmens (mokyklos) poveikį.
- σ^2 atspindi pirmo lygmens (mokinių) skirtumus, kurių nepaaiškina modelis.
- Įverčiai $\hat{\tau}_{00}$ ir $\hat{\sigma}^2$ gali būti labiau informatyvūs, nei jų statistinis reikšmingumas.

85

Galimi įverčiai

$$Y_{ij} = \beta_{0j} + e_{ij},$$

$$i = 1, \ldots, n_j,$$
$$j = 1, \ldots, J.$$

- Jei norime įvertinti j'tos mokyklos įtaką, tai tam galima naudoti

$$\overline{Y}_{\cdot j} = \frac{Y_{1j} + Y_{2j} + \cdots + Y_{n_j,j}}{n_j}.$$

86

Svertinis (Shrinkage) įvertis

$$\beta_{0j}^{*} = \lambda_j \overline{Y}_{\cdot j} + (1 - \lambda_j)\hat{\gamma}_{00}$$

$$\lambda_j = \frac{\hat{\tau}_{00}}{\hat{\tau}_{00} + \hat{\sigma}^2/n_j}$$

87

Bendrasis modelis

- Pirmas lygmuo

$$Y_{ij} = \beta_{0j} + \beta_{1j}X_{1ij} + \beta_{2j}X_{2ij} + \ldots$$

$$+ \beta_{Kj}X_{Kij} + e_{ij};$$

$$i = 1, 2, \ldots, n_j,\ j = 1, 2, \ldots, J.$$

88

Bendrasis modelis

- Antras lygmuo

$$\begin{cases} \beta_{0j} = \gamma_{00} + \gamma_{01}W_{1j} + \ldots + \gamma_{0S}W_{Sj} + u_{0j}, \\ \beta_{1j} = \gamma_{10} + \gamma_{11}W_{1j} + \ldots + \gamma_{1S}W_{Sj} + u_{1j}, \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ \beta_{Kj} = \gamma_{K0} + \gamma_{K1}W_{1j} + \ldots + \gamma_{KS}W_{Sj} + u_{Kj}. \end{cases}$$

- (Čia, kai visi nuo visko priklauso.Dažnai W įtraukiame ne į visas lygtis).

89

Jungtinis modelis

$$Y_{ij} = \gamma_{00} + \sum_{m=1}^{S} \gamma_{0m}W_{mj} + \sum_{k=1}^{K}\sum_{m=1}^{S} \gamma_{km}W_{mj}X_{kij} + \left[u_{0j} + \sum_{k=1}^{K} X_{kij}u_{kj} + e_{ij} \right]$$

90

Prielaidos liekanoms

- $e_{ij} \sim N(0, \sigma^2)$ ir yra nepriklausomos.
- $u_{kj} \sim N(0, \tau_{kk})$.
- $Cov\left(u_{kj}, u_{mj}\right) = \tau_{km}$.
- u_{kj} ir u_{ml} nepriklausomos, kai $j \neq l$.
- u_{ml} ir e_{ij} yra nepriklausomos.

91

Fiksuoti ir atsitiktiniai parametrai

- Visi γ_{ij} yra fiksuotieji paramterai.
- Visi τ_{kj} ir σ^2 yra atsitiktiniai parametrai.

92

Pastovaus ir atsitiktinio poveikio kintamieji

$$Y_{ij} = \gamma_{00} + \sum_{m=1}^{S} \gamma_{0m} W_{mj} + \sum_{k=1}^{K} \sum_{m=1}^{S} \gamma_{km} W_{mj} X_{kij} + \left[u_{0j} + \sum_{k=1}^{K} X_{kij} u_{kj} + e_{ij} \right]$$

pastovūs

atsitiktiniai

93

HLM matricinis užrašas

Jungtinio modelio matricinis užrašas

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\gamma} + \mathbf{Z}\mathbf{u} + \mathbf{e}$$

Čia $\mathbf{X}$ - pastovaus poveikio kint.,
$\mathbf{Z}$ - atsitiktinio poveikio kint.,
$\boldsymbol{\gamma}$ - fixuoti parametrai,
$\mathbf{e}$ - pirmo lygmens liekanos,
$\mathbf{u}$ - antro lygmens liekanos.

95

Jungtinio modelio matricinis užrašas

$$\mathbf{Y} = \begin{pmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \\ \dots \\ \mathbf{Y}_J \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \\ \dots \\ \mathbf{X}_J \end{pmatrix},$$

$$\mathbf{Z} = \begin{pmatrix} \mathbf{Z}_1 & 0 & \dots & 0 \\ 0 & \mathbf{Z}_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \mathbf{Z}_J \end{pmatrix}, \mathbf{u} = \begin{pmatrix} \mathbf{u}_1 \\ \mathbf{u}_2 \\ \dots \\ \mathbf{u}_J \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} \mathbf{e}_1 \\ \mathbf{e}_2 \\ \dots \\ \mathbf{e}_J \end{pmatrix}$$

96

Jungtinio modelio matricinis užrašas

$$\boldsymbol{\gamma} = \begin{pmatrix} \gamma_{00} \\ \dots \\ \gamma_{0S} \\ \gamma_{10} \\ \dots \\ \gamma_{1S} \\ \dots \\ \gamma_{KS} \end{pmatrix}, \quad \mathbf{e}_j = \begin{pmatrix} e_{1j} \\ e_{2j} \\ \dots \\ e_{n_j j} \end{pmatrix}, \quad \mathbf{u}_j = \begin{pmatrix} u_{0j} \\ u_{1j} \\ \dots \\ u_{Kj} \end{pmatrix}$$

97

Jungtinio modelio matricinis užrašas

$$\mathbf{Y}_j = \begin{pmatrix} Y_{1j} \\ Y_{2j} \\ \dots \\ Y_{n_j j} \end{pmatrix} \qquad \mathbf{Z}_j = \begin{pmatrix} \mathbf{Z}_{1j} \\ \mathbf{Z}_{2j} \\ \dots \\ \mathbf{Z}_{n_j j} \end{pmatrix},$$

$$\mathbf{Z}_{ij} = \begin{pmatrix} 1 & X_{1ij} & X_{2ij} & \dots & X_{Kij} \end{pmatrix}$$

98

Jungtinio modelio matricinis užrašas

$$\mathbf{X}_j = \begin{pmatrix} \mathbf{Z}_{1j}\mathbf{W}_j \\ \mathbf{Z}_{2j}\mathbf{W}_j \\ \dots \\ \mathbf{Z}_{n_j j}\mathbf{W}_j \end{pmatrix},$$

$$\mathbf{W}_j = \begin{pmatrix} 1 & W_{1j} & \dots & W_{Sj} & 0 & 0 & \dots & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 & 1 & W_{1j} & \dots & W_{Sj} & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & 0 & \dots & \dots \\ 0 & 0 & \dots & 0 & 0 & 0 & \dots & 0 & \dots & W_{Sj} \end{pmatrix},$$

99

Jungtinio modelio matricinis užrašas

$$\mathbf{X}_j = \begin{pmatrix} \mathbf{Z}_{1j}\mathbf{W}_j \\ \mathbf{Z}_{2j}\mathbf{W}_j \\ \dots \\ \mathbf{Z}_{n_j j}\mathbf{W}_j \end{pmatrix},$$

$$\mathbf{W}_j = \begin{pmatrix} 1 & W_{1j} & \dots & W_{Sj} & 0 & 0 & \dots & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 & 1 & W_{1j} & \dots & W_{Sj} & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & 0 & \dots & \dots \\ 0 & 0 & \dots & 0 & 0 & 0 & \dots & 0 & \dots & W_{Sj} \end{pmatrix},$$

100

Jungtinio modelio matricinis užrašas

Y kovariacijų matrica yra

$$\mathbf{V} = \mathbf{Z}\mathbf{T}\mathbf{Z}' + \mathbf{R}.$$

Čia

$$\mathbf{T} = \begin{pmatrix} \mathbf{T}_1 & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{T}_2 & \mathbf{0} & \dots & \mathbf{0} \\ \dots & \dots & \dots & \dots & \dots \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & \mathbf{T}_J \end{pmatrix}$$

$$\mathbf{T}_j = \begin{pmatrix} \tau_{00} & \tau_{01} & \dots & \tau_{0K} \\ \tau_{10} & \tau_{11} & \dots & \tau_{1K} \\ \dots & \dots & \dots & \dots \\ \tau_{K0} & \tau_{K1} & \dots & \tau_{KK} \end{pmatrix}$$

101

Jungtinio modelio matricinis užrašas

Ir

$$\mathbf{R} = \begin{pmatrix} \mathbf{R}_1 & \mathbf{0} & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{R}_2 & \mathbf{0} & \dots & \mathbf{0} \\ \dots & \dots & \dots & \dots & \dots \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \dots & \mathbf{R}_J \end{pmatrix}.$$

Dažniausiai $\mathbf{R}_j = \sigma^2\mathbf{I}$, kur $\mathbf{I}$ yra vienetinė matrica.

102

Pastabos

- Liekanų matrica **R** gali turėti ir kitokį pavidalą.
- Tada prasideda problemos su HLM vertinimu (nes reikia nusakyti, tai kaip ta **R** atrodys).
- Lengviausias būdas – įvertinti **R,** naudojantis imties duomenimis.

103

Pavyzdys

Bostono būstų vertės prognozė taikant hierarchinį tiesinį modelį

Sandra Macijauskaitė, Evelina Monastyrska ir Mintija Šimulionytė

104

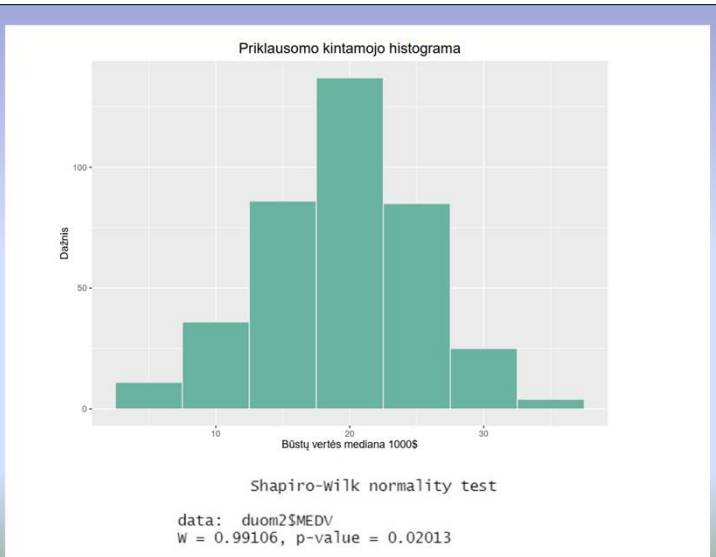
Duomenys

Duomenų rinkinys, gautas iš JAV gyventojų surašymo tarnybos surinktos informacijos apie būstus Bostono Masačiusetso valstijos teritorijoje:

- TOWNNO - rajono numeris;
- PTRATIO - mokinių ir mokytojų skaičiaus santykis pagal miestus;
- NOX - azoto oksidų koncentracija (dalimis iš 10 milijonų);
- CRIM - nusikalstamumo lygis vienam gyventojui;
- RM - vidutinis kambarių skaičius viename būste;
- LSTAT - žemesnio gyventojų statuso procentas;
- MEDV - savininkų užimtų namų vertės mediana 1000 JAV dolerių.

105

Normalumo testas




```
Shapiro-Wilk normality test

data:  duom2$MEDV
W = 0.99106, p-value = 0.02013
```

106

Besąlyginis modelis

Būsto lygmuo: $\text{MEDV} = \beta_0 + \text{e}$
Rajono lygmuo: $\beta_0 = \gamma_{00} + \text{u}_0$
Jungtinis modelis: $\text{MEDV} = \gamma_{00} + \text{u}_0 + \text{e}$

```
Linear mixed-effects model fit by REML
  Data: duom2
       AIC      BIC    logLik
  2132.786 2144.63 -1063.393

Random effects:
 Formula: ~1 | TOWNNO
        (Intercept) Residual
StdDev:    4.694678 3.279365

Fixed effects:  MEDV ~ 1
                Value Std.Error  DF  t-value p-value
(Intercept) 20.76788 0.7178257 338 28.93164       0
```

$\hat{\gamma}_{00} \approx 20,77$; $\hat{\tau}_{00} \approx 4,69^2 \approx 22,00$; $\hat{\sigma}^2 \approx 3,28^2 \approx 10,76$

107

ICC

$\hat{\gamma}_{00} \approx 20,77$; $\hat{\tau}_{00} \approx 22,00$; $\hat{\sigma}^2 \approx 10,76$

$$\begin{cases} \text{H}_0 : \gamma_{00} = 0 \\ \text{H}_1 : \gamma_{00} \neq 0 \end{cases} \qquad \begin{cases} \text{H}_0 : \tau_{00} = 0 \\ \text{H}_1 : \tau_{00} > 0 \end{cases} \qquad \begin{cases} \text{H}_0 : \sigma^2 = 0 \\ \text{H}_1 : \sigma^2 > 0 \end{cases}$$

Visos trys nulinės hipotezės yra atmetamos, daroma išvada, kad $\gamma_{00} \neq 0$, $\tau_{00} > 0$, $\sigma^2 > 0$.

$$\text{ICC} = \frac{\hat{\tau}_{00}}{\hat{\tau}_{00} + \hat{\sigma}^2} = \frac{22}{22 + 10,76} = 0,672$$

Apie 67,2 % būsto kainų priklauso nuo rajono.

108

Dviejų lygmenų modelis

1 lygio (būsto) kintamieji: CRIM, RM, LSTAT
2 lygio (rajono) kintamieji: PTRATIO, NOX

Būsto lygmuo:
$\text{MEDV} = \beta_0 + \beta_1 \cdot \text{CRIM} + \beta_2 \cdot \text{RM} + \beta_3 \cdot \text{LSTAT} + \text{e}$

Rajono lygmuo: $\beta_0 = \gamma_{00} + \gamma_{01} \cdot \text{PTRATIO} + \gamma_{02} \cdot \text{NOX} + \text{u}_0$
$\beta_1 = \gamma_{10} + \text{u}_1$
$\beta_2 = \gamma_{20} + \text{u}_2$
$\beta_3 = \gamma_{30} + \text{u}_3$

Jungtinis modelis:
$\text{MEDV} = [\gamma_{00} + \gamma_{01} \cdot \text{PTRATIO} + \gamma_{02} \cdot \text{NOX} + \gamma_{10} \cdot \text{CRIM} + \gamma_{20} \cdot \text{RM} + \gamma_{30} \cdot \text{LSTAT}] + [\text{u}_0 + \text{u}_1 \cdot \text{CRIM} + \text{u}_2 \cdot \text{RM} + \text{u}_3 \cdot \text{LSTAT} + \text{e}]$

Fiksuoto poveikio kintamieji: PTRATIO, NOX, CRIM, RM, LSTAT
Atsitiktinio poveikio kintamieji: CRIM, RM, LSTAT

Parametrų įverčiai

```
Linear mixed-effects model fit by REML
  Data: duom2
       AIC      BIC    logLik
  1809.895 1876.788 -887.9474

Random effects:
 Formula: ~1 + CRIM + RM + LSTAT | TOWNNO
 Structure: General positive-definite, Log-Cholesky parametrization
             StdDev      Corr
(Intercept) 13.54609060 (Intr) CRIM   RM
CRIM         0.02595494  0.485
RM           2.11967334 -0.991 -0.452
LSTAT        0.12396820 -0.654 -0.978  0.627
Residual     2.05260720

Fixed effects:  MEDV ~ 1 + PTRATIO + NOX + CRIM + RM + LSTAT
                Value Std.Error  DF   t-value p-value
(Intercept) 25.122266  4.675050 334  5.373689   0e+00
PTRATIO     -0.657988  0.167174  44 -3.935947   3e-04
NOX         -6.642000  2.445850 334 -2.715621   7e-03
CRIM        -0.085763  0.017982 334 -4.769332   0e+00
RM           2.634572  0.502936 334  5.238389   0e+00
LSTAT       -0.336043  0.038367 334 -8.758550   0e+00
 Correlation:
        (Intr) PTRATI NOX    CRIM   RM
PTRATIO -0.642
NOX     -0.178 -0.148
CRIM     0.183 -0.107 -0.149
RM      -0.730  0.027  0.010 -0.092
LSTAT   -0.396 -0.036 -0.142 -0.267  0.566
```

$\hat{\gamma}_{00} = 25,12$
$\hat{\gamma}_{01} = -0,66$
$\hat{\gamma}_{02} = -6,64$
$\hat{\gamma}_{10} = -0,09$
$\hat{\gamma}_{20} = 2,63$
$\hat{\gamma}_{30} = -0,34$

$\hat{\tau}_{00} = 183,33$
$\hat{\tau}_{11} = 6,76 \cdot 10^{-4}$
$\hat{\tau}_{22} = 4,49$
$\hat{\tau}_{33} = 0,02$

$\hat{\sigma}^2 = 4,21$

Modelių palyginimas

- Lyginant su besąlyginiu modeliu 60,8 % sumažėjo modeliu nepaaiškintų būstų vertės skirtumų:

$$\frac{\hat{\sigma}^2_{\text{sena}} - \hat{\sigma}^2_{\text{nauja}}}{\hat{\sigma}^2_{\text{sena}}} = \frac{10,76 - 4,21}{10,76} = 0,608$$

- Akaikės indeksas statistiškai reikšmingai sumažėjo:

	Model	df	AIC	BIC	logLik	Test	L.Ratio	p-value
model.1ml	1	17	1801.514	1868.674	-883.7567			
model.0ml	2	3	2133.950	2145.802	-1063.9749	1 vs 2	360.4364	<.0001

111

Modelis su sąveika I

1 lygio (būsto) kintamieji: CRIM, RM, LSTAT
2 lygio (rajono) kintamieji: PTRATIO, NOX

Būsto lygmuo:
$\text{MEDV} = \beta_0 + \beta_1 \cdot \text{CRIM} + \beta_2 \cdot \text{RM} + \beta_3 \cdot \text{LSTAT} + \text{e}$

Rajono lygmuo: $\beta_0 = \gamma_{00} + \gamma_{01} \cdot \text{PTRATIO} + \gamma_{02} \cdot \text{NOX} + \text{u}_0$
$\beta_1 = \gamma_{10} + \gamma_{11} \cdot \text{PTRATIO} + \text{u}_1$
$\beta_2 = \gamma_{20} + \text{u}_2$
$\beta_3 = \gamma_{30} + \text{u}_3$

Jungtinis modelis: $\text{MEDV} = [\gamma_{00} + \gamma_{01} \cdot \text{PTRATIO} + \gamma_{02} \cdot \text{NOX} + \gamma_{10} \cdot \text{CRIM} + \gamma_{11} \cdot \text{PTRATIO} \cdot \text{CRIM} + \gamma_{20} \cdot \text{RM} + \gamma_{30} \cdot \text{LSTAT}] + [\text{u}_0 + \text{u}_1 \cdot \text{CRIM} + \text{u}_2 \cdot \text{RM} + \text{u}_3 \cdot \text{LSTAT} + \text{e}]$

Fiksuoto poveikio kintamieji: PTRATIO, NOX, CRIM, RM, LSTAT, PTRATIO · CRIM
Atsitiktinio poveikio kintamieji: CRIM, RM, LSTAT

Modelių palyginimas

```
Formula: MEDV ~ 1 + PTRATIO + NOX + CRIM + RM + LSTAT + PTRATIO * CRIM +
    (1 + CRIM + RM + LSTAT | TOWNNO)
   Data: duom2

REML criterion at convergence: 1778

Scaled residuals:
    Min      1Q  Median      3Q     Max
-3.2606 -0.5117 -0.0027  0.5564  3.7313

Random effects:
 Groups   Name        Variance  Std.Dev. Corr
 TOWNNO   (Intercept) 1.834e+02 13.54086
          CRIM        4.669e-04  0.02161  0.38
          RM          4.433e+00  2.10556 -0.99 -0.42
          LSTAT       1.559e-02  0.12486 -0.67 -0.86  0.64
 Residual             4.210e+00  2.05182
Number of obs: 384, groups:  TOWNNO, 46

Fixed effects:
             Estimate Std. Error        df t value Pr(>|t|)
(Intercept)  25.81618    4.84639  81.11581   5.327 8.74e-07 ***
PTRATIO      -0.69102    0.18333  41.73094  -3.769 0.000508 ***
NOX          -6.60290    2.50238 128.99971  -2.639 0.009349 **
CRIM         -1.13525    2.05471 274.45219  -0.553 0.581046
RM            2.62601    0.50083  37.69666   5.243 6.32e-06 ***
LSTAT        -0.33539    0.03854  12.79833  -8.702 9.86e-07 ***
PTRATIO:CRIM  0.05177    0.10172 274.00960   0.509 0.611182
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Modelio be sąveikos Akaikės indeksas: 1801,514
Modelio su sąveika I Akaikės indeksas: 1814,028

Modelis su sąveika 2

1 lygio (būsto) kintamieji: CRIM, RM, LSTAT
2 lygio (rajono) kintamieji: PTRATIO, NOX

Būsto lygmuo:
$\text{MEDV} = \beta_0 + \beta_1 \cdot \text{CRIM} + \beta_2 \cdot \text{RM} + \beta_3 \cdot \text{LSTAT} + \text{e}$

Rajono lygmuo: $\beta_0 = \gamma_{00} + \gamma_{01} \cdot \text{PTRATIO} + \gamma_{02} \cdot \text{NOX} + \text{u}_0$
$\beta_1 = \gamma_{10} + \text{u}_1$
$\beta_2 = \gamma_{20} + \text{u}_2$
$\beta_3 = \gamma_{30} + \gamma_{31} \cdot \text{PTRATIO} + \text{u}_3$

Jungtinis modelis: $\text{MEDV} = [\gamma_{00} + \gamma_{01} \cdot \text{PTRATIO} + \gamma_{02} \cdot \text{NOX} + \gamma_{10} \cdot \text{CRIM} + \gamma_{20} \cdot \text{RM} + \gamma_{30} \cdot \text{LSTAT} + \gamma_{31} \cdot \text{PTRATIO} \cdot \text{LSTAT}] + [\text{u}_0 + \text{u}_1 \cdot \text{CRIM} + \text{u}_2 \cdot \text{RM} + \text{u}_3 \cdot \text{LSTAT} + \text{e}]$

Fiksuoto poveikio kintamieji: PTRATIO, NOX, CRIM, RM, LSTAT, PTRATIO · LSTAT
Atsitiktinio poveikio kintamieji: CRIM, RM, LSTAT

Modelių palyginimas

```
Formula: MEDV ~ 1 + PTRATIO + NOX + CRIM + RM + LSTAT + PTRATIO * LSTAT +
    (1 + CRIM + RM + LSTAT | TOWNNO)
   Data: duom2

REML criterion at convergence: 1781.6

Scaled residuals:
    Min      1Q  Median      3Q     Max
-3.3104 -0.5088 -0.0185  0.5467  3.7234

Random effects:
 Groups   Name        Variance  Std.Dev. Corr
 TOWNNO   (Intercept) 1.691e+02 13.0048
          CRIM        5.199e-04  0.0228   0.17
          RM          4.258e+00  2.0634  -0.99 -0.23
          LSTAT       9.486e-03  0.0974  -0.52 -0.82  0.52
 Residual             4.214e+00  2.0527
Number of obs: 384, groups:  TOWNNO, 46

Fixed effects:
             Estimate Std. Error        df t value Pr(>|t|)
(Intercept)  23.24158    5.39027  13.36695   4.312 0.000794 ***
PTRATIO      -0.52769    0.22953   8.00701  -2.299 0.050520 .
NOX          -7.11759    2.50857 105.72181  -2.837 0.005455 **
CRIM         -0.08921    0.01662  32.62100  -5.369 6.42e-06 ***
RM            2.59583    0.49211  32.93626   5.275 8.24e-06 ***
LSTAT        -0.10880    0.28384   3.82392  -0.383 0.721850
PTRATIO:LSTAT -0.01226   0.01489   3.98703  -0.824 0.456528
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Modelio be sąveikos Akaikės indeksas: 1801,514
Modelio su sąveika II Akaikės indeksas: 1817,628

115

Kas negerai

- Abudu modeliai su sąveikomis turėjo nereikšmingus sąveikų koeficientus; taigi sąveikos modeliuose nereikalingos.
- Besąlyginio modelio hipotezės šiems duomenims yra beprasmiškos. Jas reikia taikyti centruotiems duomenims (duomuo – vidurkis).

116